Homework 2: Detect AI Generated Text

314831014 呂茗憲 Github 網址

1. Data Analysis & Baseline Performance

首先對資料集進行了探索性資料分析（EDA），以了解人類撰寫與 AI 生成文本在統計上的潛在差異 。

(1) Exploratory Data Analysis (EDA):

透過分析文本的字數（Word Count）與詞彙豐富度（Type-Token Ratio, TTR），我觀察到以下現象：

- **字數分布**：人類文本的平均字數（418.3 詞）高於 AI 文本（329.4 詞），且人類文本的平均數明顯大於中位數（383.0 詞），呈現右偏態，顯示有少數極長的文本拉高了整體平均。此外，從標準差來看，人類文本的字數變異極大（std = 189.3），反映了人類文本風格與長度的多樣性；反觀 AI 文本的平均數與中位數極為接近，且標準差較小（std = 94.3），這表明 LLM 在生成文本時具有高度的長度一致性與結構制式化。

```
--- 詞數統計 ---
Human 文本 - 平均詞數: 418.3, 中位數: 383.0, 標準差: 189.3
AI    文本 - 平均詞數: 329.4, 中位數: 328.0, 標準差: 94.3
```

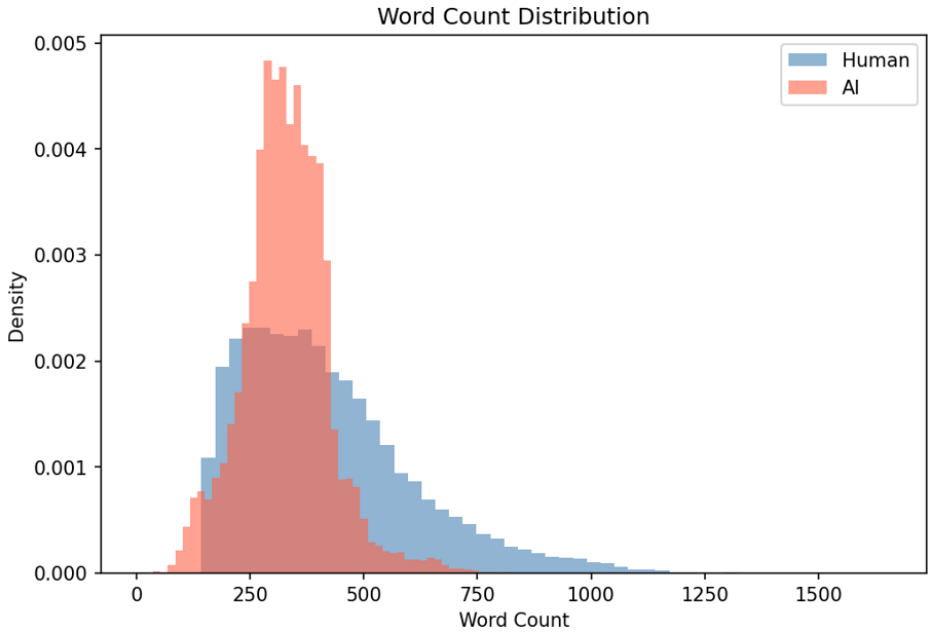

- **詞彙豐富度：** AI 生成文本的平均 TTR（0.5104）高於人類文本（0.4785）。這打破了「機器生成文本較為單調」的傳統直覺。分析其原因，可能是因為該資料集中的人類樣本傾向於重複使用特定的基礎詞彙與句型；而大型語言模型（LLM）具備龐大的詞彙庫，且生成機制通常會避免過度重複用詞，使得 AI 文本在用詞多樣性上反而略勝一籌。此外，兩者在標準差上表現相近（AI 為 0.0912，人類為 0.0826），顯示兩類文本在詞彙豐富度的波動範圍上並無極端差異。

```
--- 詞彙豐富度 (Type-Token Ratio) ---
Human 文本 - 平均: 0.4785, 標準差: 0.0826
AI    文本 - 平均: 0.5104, 標準差: 0.0912
```

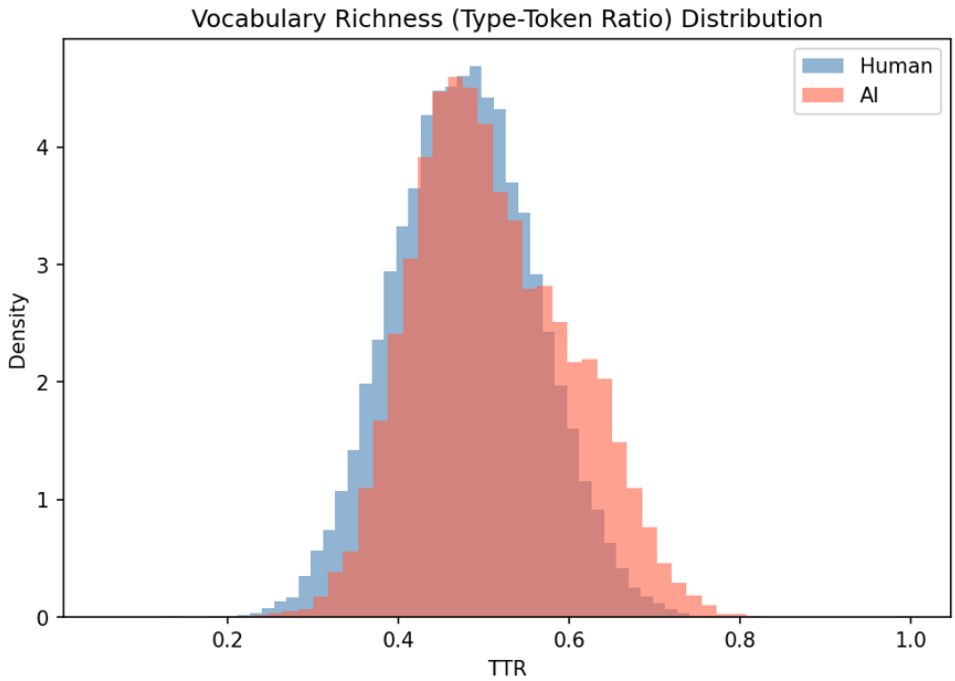

(2) Baseline Model: 作為後續 BERT 模型的效能基準，實作了 TF-IDF 搭配 Logistic Regression 分類器 。

Baseline ROC-AUC Score: 0.9993

```
訓練 TF-IDF + Logistic Regression Baseline...

 Baseline TF-IDF + LR 結果:
  ROC-AUC  : 0.9993
  Accuracy : 0.9939
```

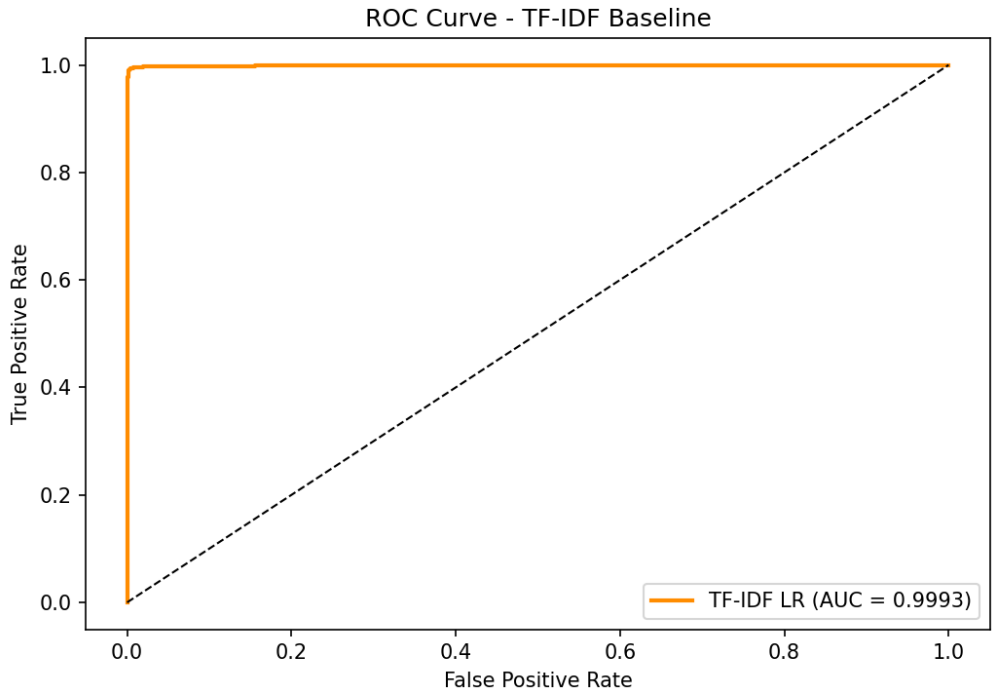

---

2. BERT Fine-Tuning & Scaling Analysis

本階段運用 Hugging Face 的 transformers 庫，針對序列分類任務微調了兩個不同參數規模的 BERT 模型 。為了在 24GB VRAM 的環境下最大化硬體效能，訓練過程中啟用了 fp16 混合精度，並透過梯度累積（Gradient Accumulation）將大型模型的等效 Batch Size 提升至與基礎模型相同的 32 。

(1) Performance Comparison:

以下為基準模型與兩個 BERT 變體的 ROC-AUC 表現比較 ：

Model Architecture	Parameters	ROC-AUC Score
TF-IDF + Logistic Regression	N/A	0.9993
BERT-Base-Cased	110M	0.9999
BERT-Large-Cased	340M	0.9999

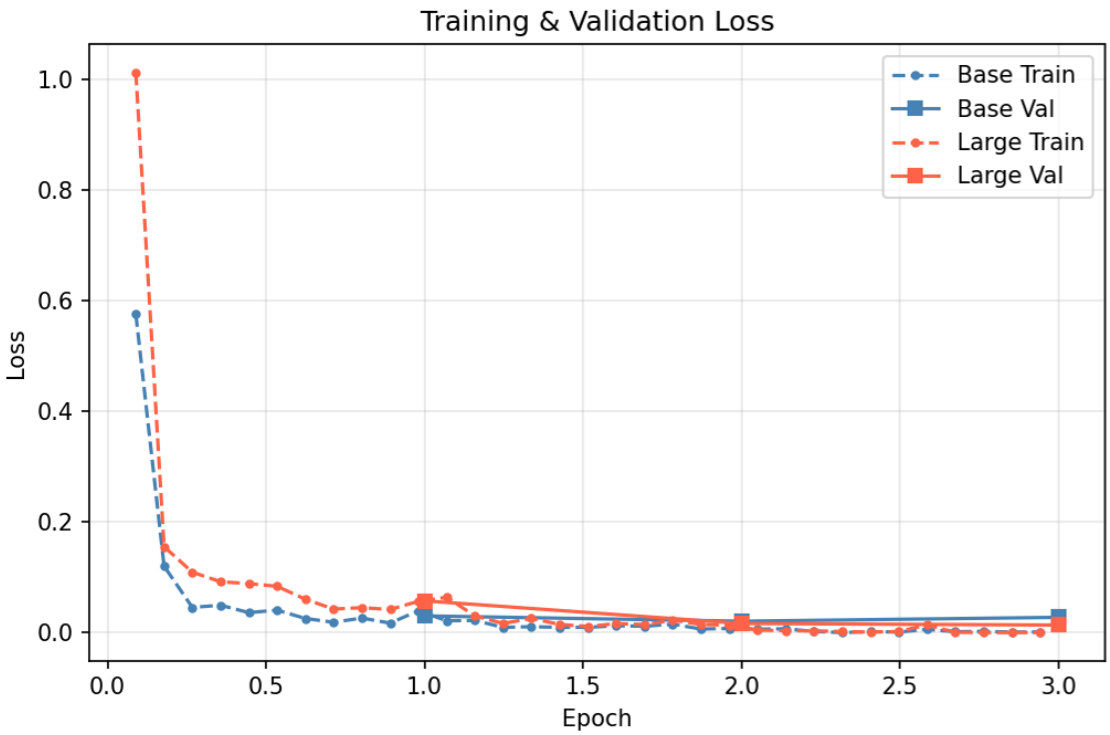

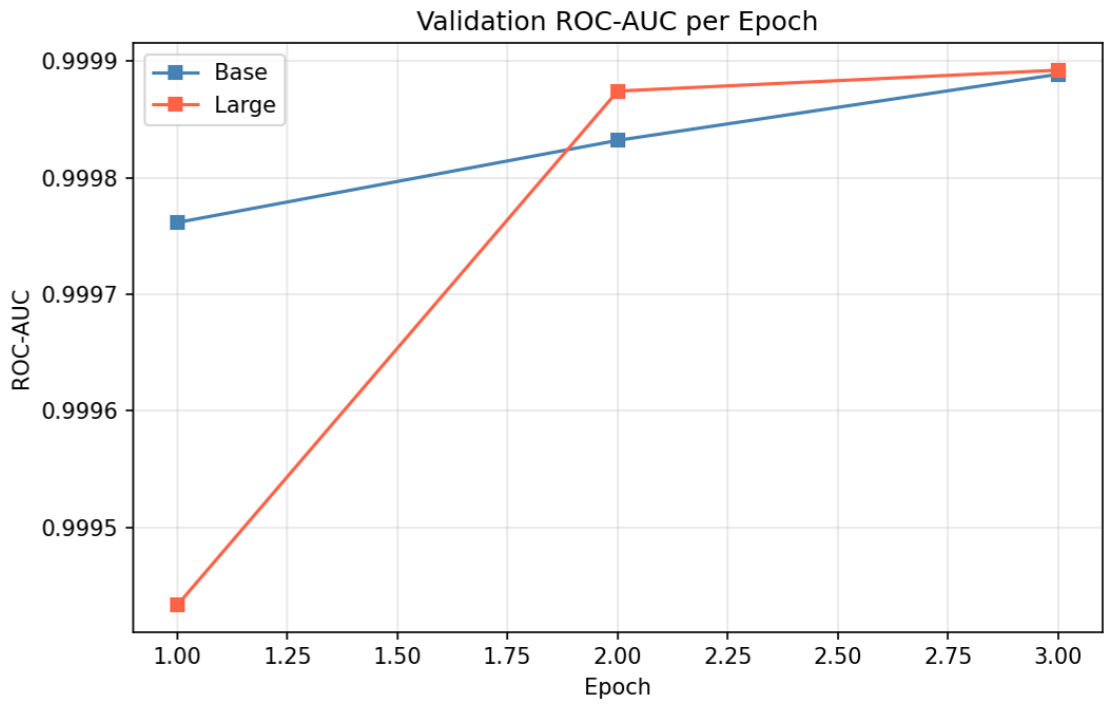

(2) Scaling Analysis (Hypothesis & Findings):

在從基礎模型（110M）擴展至大型模型（340M）的比較中，我觀察到一個值得注意的現象：兩者在驗證集上皆達到了近乎完美的 ROC-AUC 分數（0.9999），在預測效能上並無差異。針對此結果，我們提出以下運算資源與效能取捨（Trade-off）的分析：

- **天花板效應與特徵飽和（Ceiling Effect & Feature Saturation）**：此結果顯示，在當前的資料集中，AI 生成文本與人類文本之間存在極度明顯的統計或語意邊界，例如前述 EDA 觀察到的長度與詞彙豐富度差異。BERT-Base 的模型容量已經足以完全捕捉這些特徵並建立完美的決策邊界，導致更深層的 BERT-Large 無法帶來額外的邊際效益。
- **資源投入的投資報酬率（ROI of Resource Trade-off）**：由於效能已達飽和，擴展至 BERT-Large 在此情境下是不具成本效益的。大型模型不僅佔用超過兩倍的 VRAM、訓練時間大幅增加，且需要依賴梯度累積（Gradient Accumulation）才能維持相同的有效 Batch Size，卻未能換取更高的準確率。
- **結論**：對於特徵差異顯著的文本分類任務，一味追求大型模型並非最佳策略。採用輕量化的 BERT-Base 不僅能達到相同的完美分類表現，在運算成本與實際部署的推論延遲上皆具備絕對優勢。

```
============================================================
Part 2 結果摘要
============================================================
Model                                ROC-AUC
-----------------------------------------
bert-base-cased                       0.9999
bert-large-cased                      0.9999

bert-large vs bert-base 差異: +0.0000
結論：兩模型表現相近，Scale-up 效益有限（此任務特性使然）
```

---

3. Adversarial Attack Findings

靜態測試集往往無法反映模型在真實世界遭遇刻意繞過時的穩定性。在本階段，我們透過本地部署 Mistral-7B-Instruct-v0.3 ，對經過訓練的 BERT 檢測器發動對抗式攻擊 。

(1) Attack Strategy:

我們挑選了 10 篇原本被正確分類的人類文本，要求 Mistral-7B 重新改寫這些內容，並透過 Prompt 指示模型「使用較簡單的單字、更短的句子與隨性的語氣，模仿高中生的寫作風格」。

(2) Adversarial Results Overview:

在此階段的對抗式攻擊實驗中，我使用 Mistral-7B 對 10 筆原本被 BERT 完美識別為人類的樣本（原平均 AI 機率為 **0.0000**）進行了風格改寫攻擊。實驗結果顯示：

- **攻擊成功率：0%**（0 / 10 筆被誤判為人類）。
- **攻擊失敗率：100%**（10 / 10 筆仍被判定為 AI）。
- **攻擊後 AI 機率：平均 0.9958**（其中 9 筆機率高達 **1.00**，僅第 6 筆樣本微幅降至 **0.97**）。

```
==========================================
Part 3 結果統計
==========================================
攻擊成功（判為 Human）: 0 / 10  (0%)
攻擊失敗（仍判為 AI）: 10 / 10

原文 AI 機率     平均: 0.0000
攻擊後 AI 機率   平均: 0.9958
```

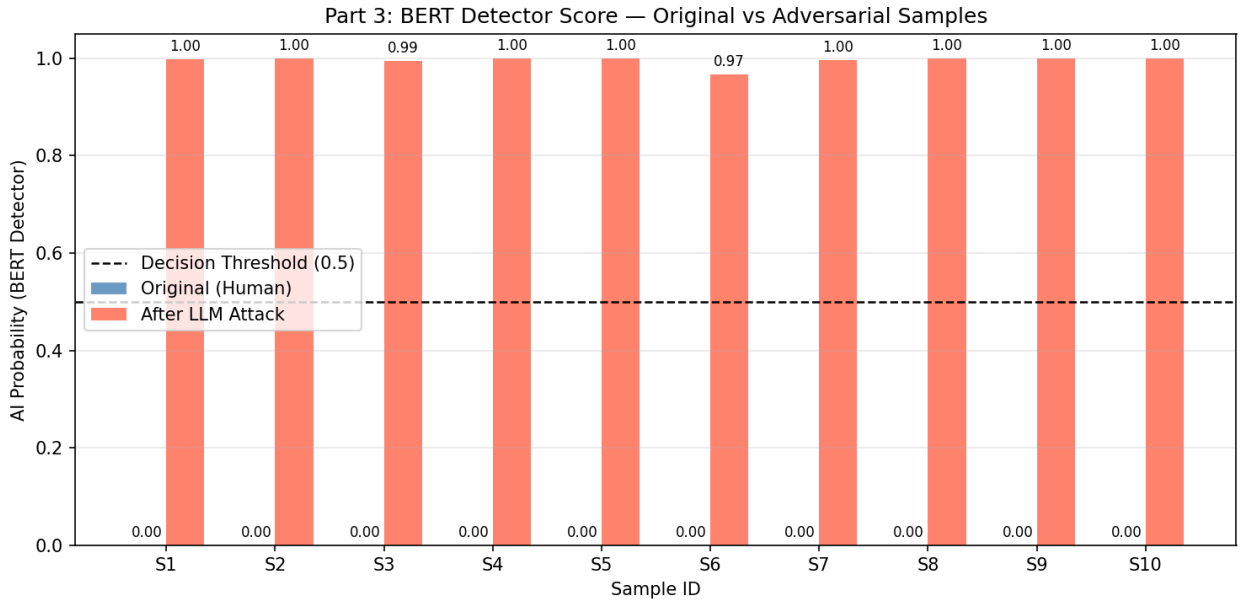

(3) Analysis: Why the Attack Failed (BERT's Robustness):

面對 Mistral-7B 壓倒性的攻擊失敗，我們從模型生成的本質與檢測器的決策機制提出以下探討：

- **LLM 的深層統計特徵難以透過 Prompt 抹除（Statistical Signatures）**：儘管我們在 Prompt 中明確指示生成模型「模仿高中生寫作」、「使用簡單單字」與「加入隨性語氣」，Mistral-7B 產出的文本依然無法擺脫 AI 固有的低困惑度（Low Perplexity）與均勻的突發性（Burstiness）。這證實了「基於提示詞的風格轉換（Prompt-based Style Transfer）」僅能改變表層的詞彙選擇，無法掩蓋 LLM 底層演算法的生成痕跡。

- **BERT 檢測器的深層語意捕捉能力（Deep Semantic Representation）**： 結合 Part 2 中 BERT 達到近乎完美（**0.9999**）的表現，這 10 筆防禦成功的數據進一步證實，我們微調的 BERT 模型並非單純「死背」某些特定的 AI 常用語。相反地，它已經學會了辨識 AI 與人類在語法結構、上下文連貫性上的深層邊界，因此面對刻意掩飾的對抗樣本仍展現出極高的防禦力。

- **Case Study: The Outlier (Sample #6)** 在所有攻擊樣本中，唯一的例外是第 6 筆樣本，其 AI 機率為 **0.97**（未達其他樣本的 **1.00**）。這表明該篇改寫文本可能在某些局部段落成功引入了較高的人類寫作特徵（例如不規則的斷句或特定的口語化表達）。然而，這種微小的擾動仍遠不足以跨越 **0.5** 的決策門檻（Decision Threshold）來騙過分類器。
  以下為第 6 筆攻擊樣本:


```
    "attack_text": "Alright, let's dive into this Venus thing NASA's been trippin' about! You know, our sis
planet that's got them stumped on how to build a ride that can handle the crazy differences from Earth.\n\nSo,
the author's like, \"Yo, we need to crack this Venus code, but it ain't gonna be easy!\" They're talkin' about
the atmospheric stuff (like sulfuric acid and insane pressure), the heatwaves (enough to melt lead), geological
and weather weirdness. NASA gotta keep all that in mind and figure out how to roll with the punches.\n\nSince
Venus is like a whole different world, NASA's had to cook up some whacky vehicles to explore it safely. The
author's all, \"Check out this blimp-like deal, it can cruise Venus for up to three weeks!\" But there's a catch
- this blimp can't touch down to collect samples for NASA to study when they get back.\n\nThe author gets that
NASA's hustlin' on some other ways to get closer to Venus' surface for some proper research. They spill the beans
on some techy methods they're cookin' up to get closer without blowin' up their vehicles or burnin' a hole in
their pockets. They even mention a plan to drill through the crust, but they ain't sayin' much about that.\n\nSo,
there you have it, folks. NASA's got their work cut out for 'em when it comes to Venus, but they're not backing
down. Let's keep our fingers crossed for some breakthroughs!",
```

4. 心得與反思

在這次作業的實作過程中，透過從資料探索（EDA）、模型微調（Fine-tuning）到對抗式攻擊（Adversarial Attack）的完整流程，我對於 BERT 架構在自然語言處理中的強大能力有了更深刻的體會。這次作業也讓我了解到 AI 生成文本的檢測應用，目前 BERT 雖能有效識別現有 LLM 的生成痕跡，但隨著生成模型如 Llama-3 或 Mistral 的演進，生成文本將愈發趨向人類的分佈規律。未來的研究方向或許不應僅止於靜態的文本分類，如何結合更動態的對抗訓練（Adversarial Training）或檢測生成模型底層的生成痕跡，將是維護數位資訊可信度的關鍵課題。